

Analyse des conditions de vie

dans les pays de l'OCDE (2017)

Modélisation des variables latentes



Ikram Abouzayd & Amélie Pirès

Master Econométrie Appliquée

Année universitaire 2025-2026

Sommaire

1) Introduction	2
2) Analyse exploratoire des données	3
2.1 Analyse univariée	3
2.2 Analyse bivariée	4
3) Réduction de dimension et analyse des structures latentes	5
3.1 Analyse en composantes principales (ACP)	5
4) Modélisation de la satisfaction dans la vie	6
4.1 Régression linéaire	6
4.2 Régression sur composantes principales (PCR)	6
4.3 Régression PLS (Partial Least Squares)	7
4.4 Comparaison des modèles	9
5) Classification des profils de bien-être (Bonus)	9
5.1 PLS-DA	9
5.2 sPLS-DA	10
5.3 Synthèse	11
6) Conclusion	12
7) Annexe	13
7.1 Tableaux	13
7.2 Graphiques	18

1) Introduction

Aujourd'hui, le développement d'un pays ne peut plus être réduit à son seul niveau de richesse. Si des indicateurs économiques comme le revenu ou la production restent importants, ils ne suffisent plus à rendre compte des conditions de vie réelles des populations. Le bien-être dépend en effet d'un ensemble de dimensions plus larges, telles que l'emploi, l'éducation, la santé, l'environnement ou encore les conditions de vie au quotidien.

Dans ce contexte, la satisfaction dans la vie apparaît comme un indicateur particulièrement intéressant. Elle permet d'avoir une vision globale du bien-être, en prenant en compte à la fois des éléments objectifs, comme les ressources économiques, mais aussi des aspects plus subjectifs liés à la perception qu'ont les individus de leur situation. Elle constitue donc une mesure synthétique pertinente pour comparer les niveaux de bien-être entre les pays.

À partir de là, plusieurs questions se posent naturellement. Les pays les plus riches sont-ils forcément ceux où les populations se déclarent les plus satisfaites ? Quels sont les facteurs qui jouent réellement un rôle dans le bien-être : les revenus, l'emploi, l'éducation, ou encore la qualité de l'environnement ? Et surtout, peut-on identifier différents profils de pays selon leur niveau de satisfaction dans la vie ?

Pour répondre à ces questions, cette étude s'appuie sur un jeu de données portant sur 38 pays de l'OCDE en 2017, décrits à partir de 22 variables au total, incluant la variable d'intérêt. Celui-ci regroupe différents indicateurs couvrant les principales dimensions du bien-être : les conditions économiques (revenu disponible, patrimoine), le marché du travail (taux d'emploi, insécurité), l'éducation, la santé, ainsi que des variables liées à l'environnement et aux conditions de vie. Dans ce cadre, la satisfaction dans la vie constitue la variable centrale, tandis que les autres variables sont utilisées pour expliquer les différences observées entre pays.

L'analyse est structurée en plusieurs étapes. Dans un premier temps, une analyse exploratoire est réalisée afin de mieux comprendre les relations entre les variables. Une analyse en composantes principales (ACP) permet ensuite de résumer l'information et d'identifier les grands axes qui structurent les différences entre pays. Dans un second temps, des modèles de régression (PCR et PLS) sont mobilisés afin d'expliquer la satisfaction dans la vie à partir des variables disponibles. Enfin, des méthodes de classification (PLS-DA et sPLS-DA) sont utilisées pour distinguer différents profils de pays et identifier les facteurs les plus discriminants du bien-être.

Ainsi, cette étude vise à proposer une analyse globale des conditions de vie dans les pays de l'OCDE, en combinant plusieurs approches statistiques complémentaires, afin de mieux comprendre les déterminants du bien-être.

2) Analyse exploratoire des données

2.1 Analyse univariée

L'analyse univariée constitue une première étape importante pour mieux comprendre les données et les différences de conditions de vie entre les pays de l'OCDE. Elle permet d'observer la distribution de chaque variable, d'évaluer leur dispersion et d'identifier d'éventuelles valeurs atypiques.

Les statistiques descriptives visible dans **Tableau 1**, montrent tout d'abord que les variables ne présentent pas le même niveau de variabilité. Les indicateurs économiques, comme le revenu disponible des ménages, le patrimoine financier ou les revenus du travail, sont relativement dispersés . Cela traduit des écarts importants entre les pays, ce qui est cohérent avec les différences de niveau de développement économique. À l'inverse, certaines variables comme les années d'éducation ou certains indicateurs de santé sont plus concentrées autour de leur moyenne, ce qui suggère des situations plus homogènes.

La satisfaction de vie se distingue justement par une dispersion plus faible. Avec une moyenne de 6,53 et un écart-type modéré, elle apparaît relativement stable d'un pays à l'autre . Les valeurs restent dans un intervalle assez restreint, ce qui montre que, même si les conditions de vie diffèrent, les niveaux de satisfaction ne varient pas autant que les variables économiques. Cela met déjà en évidence le fait que le bien-être ne dépend pas uniquement des ressources matérielles.

L'analyse des histogrammes (**Graphique 1**) confirme ces observations . Certaines variables présentent des distributions asymétriques, notamment celles liées au marché du travail ou aux conditions de logement, avec quelques pays qui se démarquent nettement. À l'inverse, la satisfaction de vie a une distribution plus symétrique et centrée autour de sa moyenne, ce qui renforce l'idée d'une certaine homogénéité entre pays.

Les boxplots (**Graphique 2**) permettent également de repérer la présence de valeurs atypiques . Celles-ci concernent surtout les variables économiques ou sociales, où certains pays apparaissent en situation très différente des autres. En revanche, la satisfaction de vie présente peu de valeurs extrêmes et une dispersion relativement faible, ce qui confirme son caractère stable.

D'un point de vue économique, ces résultats suggèrent que les écarts de bien-être ne suivent pas exactement les écarts de richesse. En effet, même si les différences de revenus sont importantes entre pays, la satisfaction de vie reste globalement proche. Cela montre que le bien-être repose sur plusieurs dimensions, et pas uniquement sur les conditions économiques.


2.2 Analyse bivariée

L'analyse bivariée permet d'aller plus loin en étudiant les relations entre les différentes variables, et en particulier leur lien avec la satisfaction de vie. Elle est essentielle pour identifier les facteurs qui influencent le bien-être des individus.

Dans un premier temps, la matrice de corrélation (**Graphique 3**) montre qu'il existe globalement de fortes corrélations entre les variables. On observe notamment que les indicateurs économiques et sociaux évoluent souvent dans le même sens. Par exemple, le revenu disponible, le patrimoine financier ou encore le niveau d'éducation sont fortement et positivement corrélés entre eux. Cela signifie que les pays les plus favorisés sur le plan économique ont aussi, en général, de meilleures conditions sociales.

Concernant la satisfaction de vie, les corrélations les plus fortes sont positives avec des variables comme le revenu, l'emploi, l'éducation ou encore l'espérance de vie. Cela suggère que de meilleures conditions de vie sont associées à un niveau de satisfaction plus élevé. À l'inverse, certaines variables comme le chômage de long terme, l'insécurité ou la pollution sont négativement corrélées avec la satisfaction de vie, ce qui est cohérent d'un point de vue économique et social. Cependant, les corrélations concernant cette variable d'intérêt ne sont pas extrêmement élevées. Cela montre que la satisfaction de vie ne dépend pas d'un seul facteur, mais d'un ensemble de dimensions, ce qui confirme la complexité du bien-être.

Le nuage de points ci dessous représentant la relation entre le revenu et la satisfaction de vie permet de visualiser plus concrètement cette relation.



On observe une tendance globalement croissante : les pays ayant un revenu plus élevé ont tendance à présenter une satisfaction de vie plus importante. Toutefois, la relation n'est pas parfaitement linéaire et les points restent assez dispersés. Cette dispersion est importante à noter, car elle montre que des pays ayant des niveaux de revenu similaires peuvent avoir des niveaux de satisfaction différents. Autrement dit, le revenu joue un rôle, mais il n'explique pas entièrement le bien-être. D'autres facteurs, comme les conditions sociales, la santé ou encore la qualité de vie, interviennent également.

Les observations graphiques ont été complétées par des tests de détection de valeurs atypiques. Le test de Grubbs (**Tableau 2**) met en évidence une valeur atypique significative pour le patrimoine financier des ménages. Le test ESD de Rosner (**Tableau 3**) signale également plusieurs valeurs atypiques sur certaines variables, notamment liées au logement, au chômage ou à la sécurité. Afin de vérifier s'il s'agissait de véritables valeurs aberrantes ou simplement de situations particulières à certains pays, des recherches externes ont été réalisées. À l'issue de cette vérification, seules deux valeurs du taux de chômage de longue durée ont été corrigées directement dans la base de données pour deux pays, car elles paraissaient incohérentes avec les informations disponibles. En revanche, les autres valeurs atypiques ont été conservées dans le jeu de données, car elles ne correspondent pas à des erreurs de mesure mais à des écarts réels entre pays.

Enfin, le test de Shapiro-Wilk (**Tableau 4**) montre que plusieurs variables ne suivent pas une distribution normale, ce qui confirme l'hétérogénéité du jeu de données.

3) Réduction de dimension et analyse des structures latentes

3.1 Analyse en composantes principales (ACP)

Dans le prolongement de l'analyse bivariée, l'analyse en composantes principales (ACP) est utilisée afin de résumer l'information contenue dans l'ensemble des variables et de mieux comprendre la structure des données. Cette méthode est particulièrement adaptée dans notre cas car les variables sont nombreuses et présentent des corrélations importantes. Cela est confirmé par les indicateurs de qualité de l'ACP : les coefficients individuels KMO sont satisfaisants (**Tableau 5**), le test de Bartlett est significatif (**Tableau 6**), et le déterminant de la matrice de corrélation est très proche de 0 (**Tableau 7**), ce qui indique que les données se prêtent bien à une analyse factorielle.

Les variables étant exprimées dans des unités différentes (revenus, pourcentages, scores), elles ont été standardisées afin d'éviter qu'une variable domine artificiellement les autres. Par ailleurs, une attention particulière a été portée à la qualité de représentation des variables dans l'ACP. Les variables présentant des $\cos^2$ faibles sur les premiers axes, c'est-à-dire mal représentées par ces dimensions, ont été écartées, tout comme celles dont la contribution aux axes était limitée ou redondante avec d'autres indicateurs (**Tableau 8 et 9**). Ce travail de sélection a conduit à retenir un ensemble de 15 variables, correspondant aux dimensions les plus structurantes du bien-être. Cela permet de se concentrer sur l'information la plus pertinente et d'améliorer la lisibilité de l'analyse.

L'analyse des valeurs propres montre que l'essentiel de l'information est concentré sur les premières dimensions (**Tableau 10**). Le premier axe explique à lui seul environ 57,5 % de la variance, ce qui est très élevé, tandis que les axes suivants apportent des informations complémentaires plus limitées. Théoriquement, on pourrait retenir jusqu'à quatre axes (ce qui permettrait d'expliquer 81,2 % de la variance totale), mais dans cette étude, l'ACP reste une étape exploratoire. Il est donc plus pertinent de se concentrer sur les deux premiers axes, qui permettent déjà de résumer l'essentiel de la structure des données.

Le cercle des corrélations (**Graphique 5**) montre que les indicateurs liés au revenu, à l'emploi, à l'éducation, à la santé ou encore à la satisfaction de vie évoluent dans le même sens. À l'inverse, des variables comme l'insécurité du marché du travail ou le chômage apparaissent opposées. Cela met en évidence que les différentes dimensions du bien-être sont fortement liées entre elles et qu'elles traduisent globalement un même niveau de conditions de vie.

Le premier axe peut ainsi être interprété comme un axe de développement socio-économique. Comme on peut le voir sur le plan factoriel (**Graphique 6**), il oppose des pays comme la Norvège, la Suisse ou le Danemark, qui présentent des niveaux élevés de revenu, d'éducation et de satisfaction de vie, à des pays comme le Brésil ou l'Afrique du Sud, caractérisés par des conditions plus fragiles. Les pays les plus développés se situent donc clairement d'un côté de cet axe, tandis que ceux en situation plus difficile se trouvent à l'opposé. Le second axe apporte une nuance supplémentaire en distinguant certains pays selon des aspects plus spécifiques, notamment liés au marché du travail ou au capital humain. On observe ainsi que des pays comme l'Espagne, l'Italie ou encore la Pologne occupent des positions intermédiaires, ce qui reflète des situations de bien-être plus nuancées. Au final, cette représentation met bien en évidence la diversité des profils au sein des pays de l'OCDE.

Au final, l'ACP permet de bien synthétiser l'information contenue dans les données et de mettre en évidence une structure d'ensemble cohérente. Elle montre que le bien-être ne dépend pas d'un seul facteur, mais de plusieurs dimensions liées entre elles. Cette étape est donc utile pour mieux comprendre l'organisation des données et pour orienter la suite de l'analyse.

4) Modélisation de la satisfaction dans la vie

Avant d'estimer les différents modèles, les données ont été séparées en un échantillon d'apprentissage et un échantillon test, selon une logique de validation externe. L'échantillon d'apprentissage représente 70 % des observations et sert à ajuster les modèles ainsi qu'à sélectionner, lorsque nécessaire, le nombre optimal de composantes. Les 30 % restants sont conservés pour l'évaluation des performances prédictives sur des données non utilisées lors de l'estimation. Ce même principe de découpage est retenu pour la régression linéaire, la PCR et la PLS, afin de comparer les méthodes dans des conditions cohérentes. Dans la partie bonus consacrée à la classification, un découpage du même type est également appliqué après discrétisation de la variable de satisfaction dans la vie en trois groupes.

4.1 Régression linéaire

Dans un premier temps, une régression linéaire classique est estimée afin d'expliquer la satisfaction dans la vie à partir de l'ensemble des variables disponibles. Ce modèle sert ici de point de comparaison, afin d'évaluer ensuite l'intérêt des méthodes de réduction de dimension.

Cependant, comme cela a déjà été observé dans l'analyse exploratoire, les variables explicatives sont fortement corrélées entre elles. Cette situation pose un problème de multicollinéarité, c'est-à-dire que plusieurs variables apportent en partie la même information. Dans ce cas, il devient plus difficile pour le modèle de distinguer précisément l'effet propre de chaque variable, ce qui peut rendre les coefficients moins stables et les résultats plus difficiles à interpréter.

Ce phénomène est confirmé par le calcul des VIF (Variance Inflation Factor) (**Tableau 11**). Plusieurs variables présentent des valeurs élevées, et certaines dépassent même largement le seuil de 10, qui est généralement considéré comme le signe d'une multicollinéarité importante. C'est notamment le cas du revenu du travail, du taux d'emploi, du revenu disponible des ménages, de la qualité de l'eau, des compétences des élèves ou encore de l'espérance de vie. Cela montre que plusieurs dimensions du bien-être évoluent fortement ensemble, ce qui est cohérent d'un point de vue économique, mais problématique pour une régression linéaire classique.

Les résultats obtenus sur l'échantillon test (**Tableau 12**) confirment ces limites. Le modèle présente un R^2 d'environ 0,10 et un RMSE proche de 0,76, ce qui signifie qu'il explique assez mal la satisfaction dans la vie et que ses prédictions restent peu précises.

Au final, ces résultats montrent que, dans notre cas, la régression linéaire classique n'est pas la méthode la plus adaptée. Elle exploite difficilement l'information contenue dans des variables très liées entre elles. Cela justifie donc le recours à des méthodes comme la PCR ou la PLS, qui permettent de résumer l'information à travers des composantes latentes et de mieux gérer ce problème de multicollinéarité.

4.2 Régression sur composantes principales (PCR)

Comme l'a montré l'ACP, les variables décrivant les conditions de vie sont fortement corrélées entre elles et semblent en grande partie organisées autour d'une dimension commune. Dans ce contexte, l'utilisation d'une régression linéaire classique devient rapidement limitée, car la multicollinéarité rend les estimations moins stables et plus difficiles à interpréter. La régression sur composantes principales (PCR) permet de contourner ce problème en s'appuyant sur des composantes construites à partir des variables initiales, mais non corrélées entre elles.

L'idée est donc de ne plus utiliser directement toutes les variables de départ, mais un nombre plus réduit de dimensions synthétiques, capables de résumer l'essentiel de l'information tout en supprimant les redondances. Dans la continuité du protocole présenté ci-dessus, la PCR est estimée sur l'échantillon d'apprentissage, puis évaluée sur l'échantillon test. Comme les variables sont exprimées dans des unités différentes, elles sont centrées et réduites avant l'estimation.

Le choix du nombre de composantes repose sur une validation croisée de type Leave-One-Out (LOO). Cette méthode a été retenue car l'échantillon reste de taille relativement réduite. À chaque étape, une seule observation est laissée de côté, tandis que toutes les autres sont utilisées pour estimer le modèle. Cela permet d'utiliser un

maximum d'information tout en évaluant la capacité du modèle à généraliser. Ce choix paraît donc bien adapté à notre cas.

Les résultats montrent que l'essentiel de la performance est obtenu dès la première composante. En effet, comme on l'observe dans **Graphique 7** le RMSEP diminue fortement entre 0 et 1 composante, puis il varie beaucoup moins par la suite. De la même manière, le R^2 augmente nettement avec la première composante avant d'atteindre rapidement un palier. Cela signifie que la première dimension capte déjà une grande partie de l'information utile pour prédire la satisfaction dans la vie.

La règle du one sigma conduit ainsi à retenir une seule composante. Ce choix est cohérent à la fois sur le plan statistique et sur le plan de l'interprétation. Avec 1 composante, on obtient un modèle plus simple, plus stable et plus facile à lire, tout en conservant déjà de bonnes performances prédictives. Cette composante peut d'ailleurs être interprétée comme un niveau global de conditions de vie, ce qui prolonge directement les résultats obtenus avec l'ACP.

L'analyse des performances sur l'échantillon test permet toutefois de nuancer ce résultat (**Tableau 13**). Le passage de 1 à 2 puis 3 composantes améliore légèrement les performances : le R^2 passe d'environ 0,56 à 0,59, tandis que le RMSE diminue de 0,53 à 0,51. Ce gain existe donc bien, mais il reste faible. En pratique, 1 composante suffit déjà à résumer l'essentiel de l'information utile, ce qui en fait un bon compromis entre simplicité, stabilité et qualité de prédiction. Au-delà de 3 composantes, les performances ne s'améliorent plus et finissent même par se dégrader, avec une baisse du R^2 et une hausse du RMSE. Cela suggère que les composantes supplémentaires apportent surtout du bruit et conduisent progressivement à un sur-ajustement. Ainsi, même si un modèle à 2 ou 3 composantes est légèrement plus performant, le choix d'une seule composante reste le plus pertinent, car il permet d'obtenir un modèle presque aussi efficace, tout en étant plus robuste et plus facile à interpréter.

Enfin, le graphique des valeurs réelles et prédites confirme que le modèle à une composante reproduit correctement la tendance générale (**Graphique 8**). La majorité des points se situe relativement près de la diagonale, ce qui montre que les prédictions restent cohérentes avec les valeurs observées. On remarque toutefois une légère sous-estimation pour les niveaux de satisfaction les plus élevés. Cela reste logique : en résumant l'information dans une seule dimension principale, le modèle restitue bien la structure d'ensemble, mais il lisse davantage les situations les plus extrêmes.

4.3 Régression PLS (Partial Least Squares)

Comme cela a déjà été mis en évidence avec l'ACP puis avec la PCR, une grande partie de l'information contenue dans les variables de conditions de vie semble pouvoir être résumée par une dimension commune. Pour rappel, cette première composante correspond globalement à un axe de conditions de vie et de bien-être, opposant les pays les mieux dotés en revenu, emploi, éducation, santé ou qualité de l'environnement à ceux dont les indicateurs sont plus défavorables. La méthode PLS s'inscrit dans cette même logique de réduction de dimension, mais avec une différence importante : contrairement à la PCR, les composantes ne sont pas construites uniquement à partir des variables explicatives, elles le sont aussi en tenant compte directement de la variable à expliquer. La PLS est donc particulièrement intéressante lorsque l'objectif principal est la prédiction.

Comme pour la PCR, le choix du nombre de composantes repose ici sur une validation croisée de type Leave-One-Out (LOO), qui est bien adaptée à la taille relativement réduite de notre échantillon. Les résultats du **Graphique 9** montrent que la majeure partie de la performance est obtenue dès la première composante. L'erreur de prédiction diminue fortement entre 0 et 1 composante, puis évolue très peu ensuite. Cela confirme, dans la continuité de la PCR, que la relation entre les variables explicatives et la satisfaction dans la vie est en grande partie portée par une seule dimension principale.

Cette idée est confirmée par l'évolution du RMSE sur les données d'apprentissage et de test (**Graphique 10**). Le RMSE sur l'échantillon test atteint sa valeur la plus faible dès la première composante, autour de 0,52, puis augmente lorsque l'on ajoute des composantes supplémentaires. En parallèle, le RMSE sur l'échantillon d'apprentissage continue de diminuer. L'écart qui se creuse entre les deux indique que le modèle s'ajuste de mieux en mieux aux données d'apprentissage, mais perd en capacité de généralisation sur de nouvelles observations. Cela traduit donc un phénomène de sur-ajustement.

Le **Tableau 14** va dans le même sens. Le R^2 sur l'échantillon test est le plus élevé avec une seule composante, autour de 0,58, puis diminue à mesure que le nombre de composantes augmente. Contrairement à la PCR, pour laquelle l'ajout de deux ou trois composantes apportait encore une légère amélioration, la PLS donne ici son meilleur résultat dès la première composante. Cela montre qu'un modèle simple suffit dans notre cas.

Le modèle retenu repose sur une seule composante, ce qui permet de conserver une approche à la fois simple, stable et efficace pour la prédiction.

Tableau 15 : Performance globale du modèle PLS

Modele	Composantes	R2_train	R2_test	RMSE_test
PLS	1	0.554	0.584	0.519

Comme l'indique le **Tableau 15** ci-dessus, ce modèle explique environ 58 % de la variabilité de la satisfaction dans la vie, avec un RMSE proche de 0,52 sur l'échantillon test. Les résultats obtenus sont légèrement meilleurs que ceux de la PCR, ce qui confirme l'intérêt de la PLS lorsque l'objectif principal est d'améliorer la qualité de la prédiction.

L'analyse des VIP permet d'identifier les variables qui jouent le rôle le plus important dans la prédiction de la satisfaction dans la vie. D'après le **Graphique 11**, les variables qui ressortent le plus sont le taux d'emploi, les revenus du travail, le revenu disponible des ménages, le nombre de pièces par personne, la qualité de l'eau et l'insécurité du marché du travail. Ce résultat montre que le bien-être ne repose pas sur une seule dimension, mais sur un ensemble de conditions concrètes qui touchent à la fois à la situation professionnelle, au niveau de vie, au logement et à l'environnement. Autrement dit, les variables les plus utiles pour prédire la satisfaction dans la vie sont celles qui traduisent le plus directement la qualité des conditions de vie dans les pays. Le fait que le taux d'emploi arrive en tête est particulièrement intéressant. Cela suggère que l'accès à l'emploi ne joue pas seulement sur le revenu, mais aussi plus largement sur la stabilité économique et l'intégration sociale, deux éléments qui peuvent fortement influencer le ressenti global de bien-être. De la même manière, l'importance des revenus du travail et du revenu disponible montre que les ressources économiques restent un déterminant central de la satisfaction dans la vie. Toutefois, le modèle ne met pas uniquement en avant l'argent : la présence du nombre de pièces par personne et de la qualité de l'eau parmi les variables les plus importantes indique aussi que les conditions matérielles du quotidien et la qualité de l'environnement comptent dans l'évaluation du bien-être.

L'examen des coefficients dans le **Graphique 12** permet ensuite de comprendre dans quel sens ces variables agissent. Les coefficients positifs concernent principalement le taux d'emploi, les revenus du travail, le revenu disponible, la qualité de l'eau et le nombre de pièces par personne. Cela signifie qu'une amélioration de ces indicateurs est associée à une hausse de la satisfaction dans la vie. On peut donc en déduire que les pays où l'emploi est plus favorable, où les ressources sont plus élevées et où les conditions matérielles sont meilleures ont aussi tendance à présenter des niveaux de satisfaction plus élevés. À l'inverse, les coefficients négatifs concernent surtout l'insécurité du marché du travail et les logements sans équipements. Ici, l'interprétation est assez directe : plus les situations de précarité professionnelle ou de difficulté matérielle sont marquées, plus la satisfaction dans la vie tend à diminuer. Ces variables jouent donc comme des freins au bien-être.

Enfin, le Graphique 13 permet d'évaluer visuellement la qualité des prédictions du modèle. Dans l'ensemble, les points sont assez proches de la diagonale, ce qui montre que la PLS restitue correctement le niveau général de satisfaction dans la vie. Le modèle suit donc bien la tendance d'ensemble : lorsque la satisfaction réelle augmente, la satisfaction prédite augmente aussi. Cela confirme que la composante retenue résume une part importante de l'information utile à la prédiction. On remarque cependant que les valeurs les plus élevées de satisfaction sont souvent prédites un peu en dessous de leur niveau réel. À l'inverse, certaines valeurs plus faibles sont légèrement surestimées. Le modèle a donc tendance à ramener les prédictions vers des valeurs plus centrales. Ce comportement est assez classique avec ce type de méthode : en résumant l'information dans une seule composante, la PLS parvient bien à reproduire la structure générale des données, mais elle distingue moins finement les situations les plus extrêmes. Autrement dit, le modèle est performant pour rendre compte des différences globales entre pays, mais il reste un peu moins précis dès qu'il s'agit de retrouver exactement les niveaux de satisfaction les plus bas ou les plus élevés. Cela n'enlève pas l'intérêt du modèle, mais montre qu'il fonctionne avant tout comme un bon outil de synthèse et de prédiction globale.

4.4 Comparaison des modèles

Afin de comparer les différentes approches, on peut observer ci dessous leurs performances sur l'échantillon test.

Tableau 16 : Comparaison des performances prédictives des modèles

Modèle	Nb comp.	R ² test	RMSE test
Régression linéaire	-	0.104	0.761
PCR	1	0.563	0.532
PLS	1	0.584	0.519

Lecture :

Le modèle le plus performant est celui qui présente le R² le plus élevé et le RMSE le plus faible.

Les résultats montrent d'abord que la régression linéaire classique est de loin le modèle le moins performant. Avec un R² de 0,104, elle ne parvient à expliquer qu'une part très limitée des différences de satisfaction dans la vie entre les pays. De plus, son RMSE de 0,761 reste élevé, ce qui traduit des erreurs de prédiction importantes. En pratique, cela signifie que le modèle a du mal à approcher correctement les niveaux réels de satisfaction et qu'il restitue assez mal l'information contenue dans les données.

À l'inverse, la PCR et la PLS donnent des résultats beaucoup plus satisfaisants. Les deux modèles améliorent nettement la qualité des prédictions, tout en reposant sur une seule composante, ce qui confirme qu'une grande partie de l'information peut être résumée par une dimension commune.

Parmi les trois modèles, c'est la PLS qui obtient les meilleures performances. Elle présente un R² de 0,584 et un RMSE de 0,519, contre un R² de 0,563 et un RMSE de 0,532 pour la PCR. Même si l'écart entre les deux méthodes reste modéré, la PLS apparaît comme le modèle le plus efficace pour prédire la satisfaction dans la vie dans notre étude.

Au final, cette comparaison montre que les méthodes de réduction de dimension sont bien plus adaptées que la régression linéaire classique dans notre cas. La PLS apparaît donc comme l'approche la plus pertinente, car elle combine les meilleures performances prédictives avec un modèle qui reste simple et facile à interpréter.

5) Classification des profils de bien-être (Bonus)

5.1 PLS-DA

Dans la continuité de la PLS, qui a permis de mettre en évidence une dimension commune expliquant la satisfaction dans la vie, il est intéressant de changer d'approche. L'objectif n'est plus ici de prédire une valeur précise, mais plutôt de distinguer différents profils de pays selon leur niveau de bien-être. La méthode PLS-DA répond à cet objectif puisqu'elle permet de passer d'une logique de régression à une logique de classification.

Pour cela, la variable de satisfaction dans la vie est discrétisée en trois niveaux (« faible », « moyen » et « élevé »), ce qui permet de mieux visualiser les écarts entre pays en termes de bien-être. Comme précédemment, les données sont séparées entre un échantillon d'apprentissage et un échantillon de test afin d'évaluer la robustesse du modèle.

Le choix du nombre de composantes repose ici sur la validation croisée. Le **Graphique 14** montre que l'erreur de classification atteint son niveau le plus faible dès la première composante, aussi bien pour le BER que pour l'erreur globale. À partir de là, l'ajout de composantes supplémentaires n'améliore pas les performances. Au contraire, l'erreur remonte avec deux composantes, puis reste à un niveau proche pour les suivantes. Ce résultat suggère que l'essentiel de l'information utile à la discrimination des groupes est déjà résumé par la première dimension. Autrement dit, une seule composante suffit pour capter la structure principale qui différencie les

pays selon leur niveau de bien-être. Les composantes ajoutées ensuite n'apportent pas d'information vraiment utile pour la classification et peuvent même introduire davantage d'instabilité dans le modèle. Ce résultat est cohérent avec ce qui a été observé en PCR et en PLS : l'information semble principalement concentrée dans une seule dimension. Le choix d'une seule composante apparaît donc à la fois suffisant et cohérent.

Le **Graphique 15** permet de voir comment les groupes se répartissent sur la première composante. Les pays du groupe faible ont surtout des scores négatifs, ceux du groupe moyen occupent une position intermédiaire, et ceux du groupe élevé ont des scores positifs. Cette composante peut donc être lue comme un axe de bien-être : plus le score est élevé, plus les conditions de vie semblent favorables. Le groupe faible présente des scores assez dispersés, ce qui montre que les pays de cette catégorie partagent un niveau de bien-être plus bas, mais avec des situations qui peuvent rester différentes. Le groupe moyen est encore plus étalé, ce qui suggère qu'il rassemble des profils variés, parfois proches du groupe faible, parfois plus proches du groupe élevé. Cela explique pourquoi cette catégorie est plus difficile à distinguer. Le groupe élevé est, dans l'ensemble, plus regroupé et situé du côté positif de la composante, ce qui traduit des profils plus proches les uns des autres. On remarque toutefois un point atypique plus bas que les autres. Cela signifie qu'un pays classé dans ce groupe a un niveau de satisfaction élevé, mais présente sur certains aspects un profil un peu moins favorable que le reste de sa catégorie. Au final, ce graphique montre surtout que l'opposition est plus claire entre les groupes faible et élevé, tandis que le groupe moyen occupe une position plus mélangée. Cette lecture va dans le même sens que les résultats obtenus avec l'ACP et la PLS.

L'analyse des variables discriminantes, présentée dans le **Graphique 17**, va dans le même sens que les résultats obtenus avec la PLS. On retrouve parmi les variables les plus importantes les revenus du travail, le taux d'emploi, le revenu disponible, la qualité de l'eau ou encore les années d'éducation. Cela montre que les groupes de pays se différencient à partir des mêmes dimensions que celles qui expliquaient déjà la satisfaction dans la vie dans la partie régression : l'emploi, les ressources économiques, les conditions de vie et, plus largement, la qualité de l'environnement. La PLS-DA confirme donc l'idée déjà mise en évidence plus haut : les pays les plus favorisés sont aussi ceux qui cumulent plusieurs avantages sur ces indicateurs, alors que les groupes les moins favorables se caractérisent par des conditions économiques et sociales plus fragiles. La différence ici est que ces variables ne servent plus à prédire un score, mais à mieux séparer des groupes de pays selon leur niveau de bien-être. On remarque aussi que certaines variables, comme le niveau d'éducation, les compétences des élèves ou le patrimoine financier, contribuent moins à la discrimination des groupes. Elles restent liées au bien-être, mais elles semblent moins utiles que l'emploi, les revenus ou les conditions de vie lorsqu'il s'agit de distinguer concrètement les profils de pays.

L'évaluation du modèle sur l'échantillon test confirme ces résultats. Comme le montre la matrice de confusion (**Tableau 17**), les classes « faible » et « élevé » sont très bien identifiées, avec une classification correcte dans tous les cas. En revanche, la classe « moyen » est plus difficile à prédire, avec seulement 25 % des observations correctement classées. La majorité est confondue avec la classe « élevé ». Cette difficulté s'explique par le fait que les pays intermédiaires partagent des caractéristiques avec les deux extrêmes. Comme on l'observe dans le graphique des scores, les groupes « moyen » et « élevé » se chevauchent partiellement, ce qui rend leur distinction moins nette. Cela suggère que certains pays classés comme « moyens » présentent déjà des conditions de vie proches de celles des pays les plus favorisés.

Au final, le modèle atteint une précision globale d'environ 70 %, ce qui reste satisfaisant compte tenu de la complexité du bien-être et du nombre limité d'observations. Le fait d'obtenir ce niveau de performance avec une seule composante confirme que celle-ci capture une information essentielle pour différencier les profils de pays.

5.2 sPLS-DA

Dans le prolongement de la PLS-DA, la méthode sPLS-DA cherche non seulement à classer les pays selon leur niveau de bien-être, mais aussi à simplifier le modèle en ne retenant que les variables les plus utiles. L'intérêt est donc surtout d'obtenir une lecture plus synthétique des résultats, sans perdre l'information essentielle déjà mise en évidence dans les analyses précédentes.

Le choix du modèle repose ici sur une validation croisée qui prend en compte à la fois le nombre de composantes et le nombre de variables sélectionnées. Le **Graphique 18** montre que les meilleures performances sont obtenues

avec une seule composante et un nombre limité de variables. Le BER diminue lorsque l'on augmente progressivement le nombre de variables retenues, puis se stabilise. Le niveau le plus faible est atteint autour de 8 variables, ce qui indique qu'il n'est pas nécessaire de conserver l'ensemble des indicateurs pour distinguer les groupes de pays. À l'inverse, l'ajout d'une deuxième composante n'apporte pas de gain, ce qui rejoint ce qui avait déjà été observé en PLS, en PLS-DA, mais aussi plus largement dans l'ensemble de l'étude : l'information utile est portée avant tout par une seule dimension principale.

Le modèle retenu repose donc sur une composante et 8 variables sélectionnées. Ce résultat est intéressant, car il montre que l'on peut retrouver la structure principale des données avec un nombre plus restreint d'indicateurs. Autrement dit, quelques variables bien choisies suffisent à résumer les différences les plus importantes entre les pays en matière de bien-être.

La projection des pays dans le **Graphique 19** reste d'ailleurs proche de celle obtenue avec la PLS-DA. Les groupes faible et élevé restent bien distincts, ce qui montre que la réduction du nombre de variables ne modifie pas la structure principale de la classification. En revanche, le groupe moyen demeure plus dispersé et se confond davantage avec les deux autres. On retrouve donc la même difficulté d'interprétation que précédemment : les situations intermédiaires sont plus complexes à isoler, car elles partagent des caractéristiques avec les profils les moins favorisés comme avec les plus favorisés.

5.3 Synthèse

Au final, les deux méthodes conduisent à des résultats cohérents et montrent qu'une seule composante suffit pour résumer l'essentiel de l'information utile à la classification des pays selon leur niveau de bien-être. La PLS-DA est toutefois la méthode la plus performante sur le plan prédictif, avec une accuracy de 70 %, contre 60 % pour la sPLS-DA comme le montre le tableau ci dessous. Elle permet donc une meilleure classification globale des pays.

Tableau 18 : Comparaison entre PLS-DA et sPLS-DA

		Accuracy 70 %		
	Modele	Composantes	Accuracy	Variables
comp1	PLS-DA	1	70%	Toutes
	sPLS-DA	1	60%	8

En revanche, la sPLS-DA présente un autre avantage : elle repose sur un nombre plus restreint de variables, ici 8 seulement, ce qui rend le modèle plus simple et plus facile à interpréter. Elle met ainsi davantage en évidence les indicateurs les plus discriminants du bien-être, au prix d'une légère baisse de performance.

Ainsi, si l'objectif principal est d'obtenir la meilleure qualité de classification, la PLS-DA apparaît comme la méthode la plus adaptée. Si l'on cherche plutôt un modèle plus parcimonieux et plus lisible, permettant d'identifier les variables essentielles, alors la sPLS-DA constitue une alternative intéressante. Dans le cadre de cette étude, la PLS-DA peut être retenue comme la meilleure méthode, tandis que la sPLS-DA vient utilement compléter l'analyse par une lecture plus synthétique des facteurs du bien-être.

6) Conclusion

L'objectif de cette étude était de mieux comprendre les conditions de vie dans les pays de l'OCDE en 2017, en cherchant à identifier les principaux facteurs associés à la satisfaction dans la vie et à mettre en évidence différents profils de bien-être entre les pays. Plus largement, il s'agissait de déterminer si le bien-être pouvait être résumé par quelques dimensions communes, au-delà du seul niveau de richesse.

Les résultats obtenus montrent que le bien-être ne dépend pas d'un seul facteur, mais d'un ensemble de dimensions économiques, sociales, sanitaires et environnementales qui sont fortement liées entre elles. L'analyse exploratoire, puis l'ACP, ont mis en évidence cette structure commune et montré qu'une grande partie de l'information pouvait être résumée par une première dimension, que l'on peut interpréter comme un axe global de conditions de vie et de bien-être. Les pays les mieux situés sur cet axe sont aussi ceux qui cumulent de meilleurs résultats en matière de revenu, d'emploi, d'éducation, de santé et de qualité de l'environnement.

Les modèles de régression confirment ensuite cette lecture. La régression linéaire classique apparaît peu adaptée dans notre cas, en raison de la forte multicolinéarité entre les variables explicatives. À l'inverse, les méthodes fondées sur des composantes latentes donnent de meilleurs résultats. La PCR améliore déjà nettement la qualité de la prédiction, mais c'est la PLS qui obtient les meilleures performances sur l'échantillon test, avec un R^2 de 0,584 et un RMSE de 0,519. Cela montre qu'il est plus pertinent, dans ce type de données, de s'appuyer sur une dimension synthétique plutôt que d'utiliser directement toutes les variables initiales.

L'analyse de classification prolonge ces résultats. La PLS-DA montre qu'il est possible de distinguer plusieurs profils de pays selon leur niveau de bien-être, avec une bonne identification des groupes les plus faibles et les plus élevés. Les situations intermédiaires restent en revanche plus difficiles à classer, ce qui reflète la complexité du phénomène étudié. La sPLS-DA confirme cette structure générale tout en proposant une lecture plus simple, grâce à la sélection d'un nombre restreint de variables. Elle est un peu moins performante que la PLS-DA en termes de classification, mais elle met plus clairement en évidence les indicateurs les plus importants.

Dans l'ensemble, les résultats obtenus convergent vers une même idée : le bien-être peut être en grande partie résumé par une dimension principale, mais cette dimension repose elle-même sur plusieurs leviers essentiels, notamment l'emploi, les revenus, l'éducation, le logement, la santé et l'environnement. Autrement dit, les pays où la satisfaction dans la vie est la plus élevée ne sont pas seulement les plus riches, mais aussi ceux qui cumulent de bonnes conditions de vie dans plusieurs domaines.

Cette étude présente toutefois certaines limites. D'abord, elle repose sur un nombre limité de pays et sur une seule année d'observation, ce qui réduit la portée générale des résultats. Ensuite, la satisfaction dans la vie reste une variable complexe, qui dépend aussi de facteurs plus subjectifs, institutionnels ou culturels, difficilement mesurables dans ce cadre. Enfin, les méthodes mobilisées permettent de résumer, prédire et classer, mais elles ne suffisent pas à établir des liens de causalité.

Plusieurs prolongements pourraient être envisagés. Il serait par exemple intéressant d'étendre l'analyse à plusieurs années afin d'étudier l'évolution du bien-être dans le temps, d'intégrer d'autres variables explicatives, notamment institutionnelles ou politiques, ou encore de comparer ces résultats avec ceux obtenus à partir d'autres méthodes statistiques.

7) Annexe

7.1 Tableaux

Tableau 1 : Statistiques descriptives

variable	moyenne	mediane	minimum	maximum	sd
annees_education	17.38	17.30	14.80	21.20	1.39
chomage_long_terme_pct	3.20	1.98	0.03	16.95	3.72
competences_eleves_score	486.76	496.00	391.00	529.00	33.51
depenses_logement_pct	20.89	21.00	15.00	26.00	2.41
engagement_parties_prenant	2.05	2.10	0.80	3.50	0.70
esperance_vie_ans	79.54	81.15	57.40	83.90	4.69
insecurite_marche_travail_pct	5.48	4.00	1.50	26.50	5.11
logements_sans_equipements_pct	3.45	0.60	0.00	37.00	6.64
niveau_education_pct	77.24	81.50	37.00	95.00	16.00
participation_electorale_pct	70.03	69.50	49.00	91.00	11.67
patrimoine_financier_menag	49362.79	39468.00	2260.00	176076.00	38708.20
pieces_par_personne	1.64	1.75	0.70	2.50	0.47
pollution_air_pm25	13.39	14.00	3.00	28.00	5.90
qualite_eau_pct	82.26	84.00	54.00	99.00	10.87
revenu_disponible_menages	25113.84	24902.50	10872.00	44049.00	8026.04
revenus_du_travail_usd	37435.95	38223.00	11554.00	62636.00	14256.99
sante_declaree_bonne_pct	67.45	70.00	33.00	88.00	13.98
satisfaction_vie_score	6.53	6.65	4.80	7.50	0.78
sentiment_securite_nuit_pct	68.63	70.40	36.10	87.70	13.20
soutien_social_pct	90.03	90.50	76.00	98.00	4.59
taux_emploi_pct	67.74	69.00	43.00	86.00	8.21
taux_homicide	2.93	1.00	0.20	27.60	5.47

Tableau 2 : Analyse des valeurs aberrantes selon le test de Grubbs

variable	p_value
annees_education	0.074
depenses_logement_pct	0.214
patrimoine_financier_menages	0.008

Tableau 3 : Analyse des valeurs aberrantes selon le test ESD de Rosner

Variable	Nb atypiques	Variable	Nb atypiques
logements_sans_equipements_pct	3	niveau_education_pct	0
insecurite_marche_travail_pct	3	competences_eleves_score	2
taux_emploi_pct	0	esperance_vie_ans	2
chomage_long_terme_pct	3	sante_declaree_bonne_pct	0
soutien_social_pct	1	taux_homicide	3

Tableau 4 : Résultats du test de Shapiro-Wilk pour la normalité des variables

Variable	p.value	Variable	p.value
logements_sans_equipements_pct	0.0000	competences_eleves_score	0.0001
depenses_logement_pct	0.2545	annees_education	0.7674
pieces_par_personne	0.2862	pollution_air_pm25	0.5337
revenu_disponible_menages	0.5260	qualite_eau_pct	0.1036
patrimoine_financier_menages	0.0029	engagement_parties_prenantes_score	0.5557
insecurite_marche_travail_pct	0.0000	participation_electorale_pct	0.5656
taux_emploi_pct	0.0918	esperance_vie_ans	0.0000
chomage_long_terme_pct	0.0000	sante_declaree_bonne_pct	0.0477
revenus_du_travail_usd	0.1364	satisfaction_vie_score	0.0198
soutien_social_pct	0.0401	sentiment_securite_nuit_pct	0.0684
niveau_education_pct	0.0000	taux_homicide	0.0000

Tableau 5 : Résultats du test KMO pour l'évaluation de l'adéquation des données

Variable	Indice KMO	Variable	Indice KMO
logements_sans_equipements_pct	0.79	niveau_education_pct	0.79
pieces_par_personne	0.82	competences_eleves_score	0.72
revenu_disponible_menages	0.87	annees_education	0.8
patrimoine_financier_menages	0.92	qualite_eau_pct	0.89
insecurite_marche_travail_pct	0.75	esperance_vie_ans	0.82
taux_emploi_pct	0.86	satisfaction_vie_score	0.83
revenus_du_travail_usd	0.86	sentiment_securite_nuit_pct	0.84
soutien_social_pct	0.89		

Tableau 6 : Résultats du test de sphéricité de Bartlett

Statistique	Valeur
Chi-deux	522.18
Degrés de liberté	105
p-value	1.32e-56

Tableau 7 : Résultat du déterminant de la matrice de corrélation

Statistique	Valeur
Déterminant de la matrice de corrélation	5.29e-08

Tableau 8 : Contribution des variables aux quatre premières composantes principales

Variable	PC1	PC2	PC3	PC4
logements_sans_equipements_pct	0.73	2.33	6.94	21.10
pieces_par_personne	0.91	3.31	1.62	0.01
revenu_disponible_menages	0.99	3.54	5.91	3.01
patrimoine_financier_menages	0.61	5.55	14.24	12.33
insecurite_marche_travail_pct	0.63	14.14	0.43	1.46
taux_emploi_pct	0.85	4.93	4.19	4.26
revenus_du_travail_usd	1.08	4.74	1.62	0.76
soutien_social_pct	0.54	6.54	17.18	0.82
niveau_education_pct	0.47	13.18	1.53	15.84
competences_eleves_score	0.82	6.08	0.18	0.02
annees_education	0.44	1.19	23.73	14.54
qualite_eau_pct	0.91	0.29	6.05	0.01
esperance_vie_ans	0.81	1.39	8.90	19.70
satisfaction_vie_score	0.81	1.43	1.11	0.17
sentiment_securite_nuit_pct	1.00	0.03	0.45	2.67

Tableau 9 : Qualité de représentation des variables ($\cos^2$)

Variable	PC1	PC2	PC3	PC4
logements_sans_equipements_pct	0.06	0.03	0.07	0.22
pieces_par_personne	0.08	0.05	0.02	0.00
revenu_disponible_menages	0.09	0.05	0.06	0.03
patrimoine_financier_menages	0.05	0.08	0.15	0.13
insecurite_marche_travail_pct	0.05	0.21	0.00	0.02
taux_emploi_pct	0.07	0.07	0.04	0.04
revenus_du_travail_usd	0.09	0.07	0.02	0.01
soutien_social_pct	0.05	0.10	0.18	0.01
niveau_education_pct	0.04	0.19	0.02	0.16
competences_eleves_score	0.07	0.09	0.00	0.00
annees_education	0.04	0.02	0.25	0.15
qualite_eau_pct	0.08	0.00	0.06	0.00
esperance_vie_ans	0.07	0.02	0.09	0.20
satisfaction_vie_score	0.07	0.02	0.01	0.00
sentiment_securite_nuit_pct	0.09	0.00	0.00	0.03

Tableau 10 : Résultats des valeurs propres et de l'inertie expliquée par les axes

Axe	Valeur propre	Inertie (//%)	Inertie cumulée (//%)
Axe 1	8.63	57.52	57.52
Axe 2	1.46	9.71	67.23
Axe 3	1.06	7.09	74.31
Axe 4	1.03	6.89	81.21
Axe 5	0.82	5.49	86.69
Axe 6	0.48	3.17	89.87
Axe 7	0.37	2.47	92.34
Axe 8	0.31	2.07	94.41
Axe 9	0.22	1.48	95.89
Axe 10	0.19	1.29	97.18
Axe 11	0.17	1.13	98.31
Axe 12	0.10	0.67	98.98
Axe 13	0.07	0.46	99.44
Axe 14	0.05	0.34	99.78
Axe 15	0.03	0.22	100.00

Tableau 11 : Facteurs d'inflation de variance (VIF) du modèle linéaire

	Variable	VIF	Interprétation
7	revenus_du_travail_usd	23.35	Multicolinéarité forte
6	taux_emploi_pct	15.25	Multicolinéarité forte
3	revenu_disponible_menages	13.97	Multicolinéarité forte
12	qualite_eau_pct	11.08	Multicolinéarité forte
13	esperance_vie_ans	10.70	Multicolinéarité forte
10	competences_eleves_score	10.48	Multicolinéarité forte
5	insecurite_marche_travail_pct	7.98	Multicolinéarité modérée
1	logements_sans_equipements_pct	6.90	Multicolinéarité modérée
2	pieces_par_personne	6.35	Multicolinéarité modérée
14	sentiment_securite_nuit_pct	6.24	Multicolinéarité modérée
9	niveau_education_pct	5.20	Multicolinéarité modérée
4	patrimoine_financier_menages	3.75	Faible
8	soutien_social_pct	2.25	Faible
11	annees_education	2.16	Faible

Tableau 12 : Résultats de la régression linéaire

Indicateur	Valeur
Nombre de variables explicatives	14.000
R ² sur test	0.104
RMSE sur test	0.761

Tableau 13 : Performances du modèle PCR en fonction du nombre de composantes principales

Nombre de composantes	R ² sur test	RMSE sur test
1	0.563	0.532
2	0.592	0.514
3	0.593	0.513
4	0.586	0.517
5	0.538	0.547
6	0.567	0.529
7	0.568	0.529
8	0.529	0.552
9	0.272	0.686
10	0.236	0.703
11	0.505	0.566
12	0.472	0.585
13	0.456	0.593
14	0.104	0.761

Tableau 14 : R² sur test selon le nombre de composantes

Composantes	R ² sur test	Composantes	R ² sur test
1	0.584	8	0.315
2	0.537	9	0.229
3	0.484	10	0.108
4	0.396	11	0.099
5	0.363	12	0.100
6	0.326	13	0.104
7	0.334	14	0.104

Tableau 17 : Matrice de confusion


Classe_réelle	Faible	Moyen	Élevé
Faible	3 (100%)	0	0
Moyen	0	1 (25%)	3 (75%)
Élevé	0	0	3 (100%)

7.2 Graphiques


Graphique 1 : Histogrammes de l'ensemble des variables




Graphique 2 : Boxplot de l'ensemble des variables




Graphique 3 : Matrice de corrélation




Graphique 4 : Scree plot




Graphique 5 : Cercle des corrélations des variables des axes 1 et 2




Graphique 6 : Projection des pays des axes 1 et 2




Graphique 7 : LOO




Graphique 8 : PCR - Valeurs réelles vs prédites




Graphique 9 : Sélection du nombre optimal de composantes PLS



Graphique 10: Évolution de l'erreur de prédiction selon le nombre de composantes



Graphique 11 : Importance des variables (VIP)




Graphique 12 : Effet des variables (coefficients PLS)




Graphique 13 : PLS - Valeurs réelles vs prédites

PLS : Valeurs réelles vs prédites


R^2 sur Test = 0.584




Graphique 15 : Visualisation de l'erreur de classification selon k (PLS-DA)




Graphique 16 : Distribution des scores par groupe PLS-DA (Composante 1)



Graphique 17 : Importance des variables (VIP - PLS-DA)



Graphique 18 : Sélection des paramètres optimaux du modèle sPLS-DA



Graphique 19 : Distribution des scores par groupe sPLS-DA (Composante 1)

